



Tarea 2 Fis205

Javier Villarroel Toro¹

¹*jvillarroelt@usm.cl, Universidad Técnica Federico Santa María*

1. Problema 1: Inciso a)

1.1. Problema directo e inverso

Antes de mencionar la dificultad del proceso inverso, explicaremos en que consiste. El problema inverso consiste en deducir las causas (γ, k) a partir de los efectos observados $x(t)$. Su dificultad radica en que suele ser mal condicionado. En otras palabras, pequeños variaciones o ruidos en la señal original observada puede generar cambios drásticos en los parámetros inferidos. Además en sistemas complejos, distintas combinaciones de parámetros podrían producir señales muy similares, dificultando encontrar una solución única y estable.

1.2. Aprendizaje supervisado

Al tener un conjunto de datos de entrada y salida:

$$\{(\mathbf{x}_i, \theta_i)\}_{i=1}^N$$

Donde $\mathbf{x}_i$ es la señal observada y $\theta_i = (\gamma_i, k_i)$ son las etiquetas, conocer estas etiquetas para un proceso inverso depende de la etapa en la que se encuentra el modelo.

Si estamos entrenando un modelo de aprendizaje supervisado que resuelve un problema inverso, es estrictamente necesario conocer las etiquetas. Nuestro algoritmo necesita ejemplos de pares señal-parámetro para aprender el mapeo matemático que los conecta.

Sin embargo, si nuestro modelo ya se encuentra entrenado, su propósito justamente es interferir los parámetros de nuevas señales de las cuales no conocemos las etiquetas. Por lo tanto, no es necesario conocerlas.

1.3. Conjuntos de entrenamiento y validación

La separación de datos **train** y **test** es fundamental para evaluar la capacidad de generalización del modelo. Al mostrarle todos los datos al modelo durante el entrenamiento, este podría considerar el ruido o las fluctuaciones como parte de la física del problema, por lo tanto, no estaría aprendiendo las reglas físicas subyacentes.

Al guardar un porcentaje de los datos como conjunto de validación, podemos medir objetivamente cómo se comportará el modelo frente a señales que jamás ha visto. Si el error en **train** es muy alto, sabremos que el modelo sufrió de sobreajuste (**overfitting**).

1.4. Función de pérdida

La función de pérdida es una métrica matemática que cuantifica qué tan equivocadas están las predicciones del modelo en comparación con los valores reales (etiquetas).

El error cuadrático medio se define como:

$$MSE = \frac{1}{N} \sum_{i=1}^N [(\gamma_i - \hat{\gamma}_i)^2 + (k_i - \hat{k}_i)^2]$$

Este es importante ya que penaliza fuertemente los errores grandes. El MSE mide la distancia geométrica entre los parámetros reales y las predicciones $\hat{\gamma}_i$ y $\hat{k}_i$, al elevar los errores al cuadrado, se eliminan los signos negativos y se asegura que el modelo se esfuerce especialmente en corregir las predicciones que están más alejadas de la realidad.

2. Inciso b)

Se graficaron algunas señales




Figura 1: Gráfico de la solución numérica para el oscilador amortiguado mediante solve_ivp.

Notar que al aumentar el parámetro k , la frecuencia de oscilación $\omega_0 = \sqrt{\frac{k}{m}}$ también aumenta, la cual se logra apreciar mediante oscilaciones más rápidas en la señal.

Por otro lado, en nuestro problema, el decaimiento se refiere a la pérdida gradual de la amplitud de una señal o movimiento a lo largo del tiempo debido a la disipación de energía. El análisis de (1) revela que al aumentar el parámetro γ el decaimiento es más rápido. Por lo tanto, la amplitud cae más velozmente hacia cero. Esto es tan notorio que, para $\gamma = 1,0$ en $t = 6$ s, la oscilación se extingue casi por completo.

Por último, el ruido gaussiano ($\sigma = 0,02$) introducido en la solución añade pequeñas fluctuaciones sobre la señal limpia, simulando de manera adecuada el ruido experimental.

3. Inciso c)

Para analizar el desempeño de ambos modelos tenemos las siguientes figuras:




Figura 2: Gráficos del parámetro k y γ predichos por los modelos vs los valores reales.

Modelo	$RMSE_{\gamma}$	$RMSE_k$	R^2_{γ}	R^2_k
Random Forest	0.02082	0.10973	0.9940	0.9906
MLP Regressor	0.01217	0.02348	0.9979	0.9996

Cuadro 1: Resumen del desempeño de los modelos de regresión para $\sigma = 0,02$.

Notar que el modelo MLP supera consistentemente al modelo de Random Forest en la predicción de ambos parámetros físicos.

En términos absolutos, el parámetro k presenta valores de RMSE mayores que γ en ambos modelos. No obstante, esto se debe principalmente a las escalas físicas de las distribuciones subyacentes: mientras que γ se mueve en un rango pequeño $\mathcal{U}(0,05, 1,0)$, k abarca un intervalo mayor $\mathcal{U}(1,0, 5,0)$. Al normalizar este efecto mediante el coeficiente de determinación, ambos modelos consiguen un ajuste de $R^2 \approx 0,999$ bajo la arquitectura de la red neuronal.

4. Inciso d)




Figura 3: Gráficos de $RMSE_{\gamma}$ y $RMSE_k$ en función del ruido gaussiano σ .

Ambos RMSE crecen monótonamente con σ . Más ruido degrada la calidad de la interferencia porque enmascara las características de la señal que codifican los parámetros físicos.

El parámetro más difícil de inferir es γ que el parámetro k . Esto se debe a que k controla la frecuencia ω_0 , que se manifiesta como la periodicidad de la señal y fácil de detectar. En cambio, γ controla la envolvente exponencial, cuyo efecto es más sutil y se confunde fácilmente con el ruido.

El sobreajuste se manifiesta cuando $\text{RMSE}(\text{train}) \ll \text{RMSE}(\text{test})$. Esto es visible especialmente en RandomForest, que puede memorizar patrones de ruido sin generalizar nuevos datos. El modelo MLP controla mejor este efecto al detener el entrenamiento cuando la pérdida de validación deja de mejorar.

»En conclusión, las redes neuronales, en concreto el modelo MLP supera a RandomForest gracias a la capacidad de aprender representaciones continuas, aunque ambos modelos logren una alta precisión para k .